

Лабораторная работа №1

Исследование градиентного спуска для квадратичной формы

Студент: Шевченко О.В.
Группа: 09.04.01-ПОВа-325

18 января 2026 г.

1 Цель работы

Данная лабораторная работа посвящена практическому изучению алгоритма градиентного спуска для минимизации функции многих переменных. В качестве объекта исследования выбрана квадратичная форма вида:

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top A \mathbf{x},$$

где $\mathbf{x} \in \mathbb{R}^n$, а A – симметричная положительно определённая матрица ($A = A^\top \succ 0$).

Конкретные цели работы включают:

1. **Практическая реализация:** Освоение процедуры программирования алгоритма градиентного спуска для гладкой выпуклой функции.
2. **Исследование параметров:** Систематическое изучение влияния размера шага (скорости обучения α) на скорость сходимости и устойчивость метода.
3. **Визуальный анализ:** Для случая $n = 2$ – построение и анализ траекторий спуска в пространстве параметров на фоне линий уровня целевой функции.
4. **Сравнение с теорией:** Проверка на практике теоретических оценок скорости сходимости и условий устойчивости, связанных со спектральными свойствами матрицы A (собственными значениями λ_{\max} , λ_{\min} и числом обусловленности $\kappa = \frac{\lambda_{\max}}{\lambda_{\min}}$).

Результатом работы должно стать не только корректно работающее программное обеспечение, но и качественное понимание ключевых факторов, определяющих эффективность одного из фундаментальных методов непрерывной оптимизации.

2 Теоретическая часть

2.1 Постановка задачи оптимизации

Требуется найти точку глобального минимума $\mathbf{x}^* \in \mathbb{R}^n$ функции $f(\mathbf{x})$ и соответствующее минимальное значение f^* :

$$\mathbf{x}^* = \arg \min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}), \quad f^* = f(\mathbf{x}^*).$$

В силу свойств матрицы A (симметричность и положительная определённость) задача имеет единственное решение.

2.2 Свойства целевой функции

1. **Градиент** функции вычисляется по формуле:

$$\nabla f(\mathbf{x}) = A\mathbf{x}.$$

Необходимое и достаточное условие минимума $\nabla f(\mathbf{x}^*) = 0$ приводит к системе линейных уравнений $A\mathbf{x}^* = 0$. Так как A положительно определена (невырождена), решение единственно: $\mathbf{x}^* = \mathbf{0}$. Следовательно, $f^* = 0$.

2. **Матрица Гессе** (гессиан) функции постоянна и равна A :

$$\nabla^2 f(\mathbf{x}) = A.$$

Положительная определённость A гарантирует строгую выпуклость функции $f(\mathbf{x})$, что обеспечивает сходимость градиентного метода к глобальному минимуму при правильном выборе шага.

3. **Число обусловленности** задачи определяется собственными значениями матрицы A . Пусть $0 < \lambda_{\min} = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n = \lambda_{\max}$. Тогда число обусловленности κ есть:

$$\kappa(A) = \frac{\lambda_{\max}}{\lambda_{\min}} \geq 1.$$

Величина κ напрямую влияет на геометрию линий уровня функции $f(\mathbf{x})$. При $\kappa \approx 1$ (хорошая обусловленность) линии уровня близки к сферам. При $\kappa \gg 1$ (плохая обусловленность) они сильно вытянуты (эллипсоиды), что замедляет сходимость градиентного спуска.

2.3 Алгоритм градиентного спуска

Основная итерационная формула градиентного спуска с постоянным шагом $\alpha > 0$ имеет вид:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha \nabla f(\mathbf{x}_k) = \mathbf{x}_k - \alpha A\mathbf{x}_k = (I - \alpha A)\mathbf{x}_k, \quad (1)$$

где $k = 0, 1, 2, \dots$ – номер итерации, I – единичная матрица.

2.4 Условия сходимости и выбор шага

Скорость сходимости итерационного процесса (1) определяется спектральным радиусом матрицы перехода $G = I - \alpha A$. Для сходимости метода ($\|\mathbf{x}_k\| \rightarrow 0$) необходимо и достаточно, чтобы $\rho(G) < 1$, где $\rho(G) = \max_i |1 - \alpha \lambda_i|$.

- **Условие устойчивости:** Сходимость гарантирована при

$$0 < \alpha < \frac{2}{\lambda_{\max}}. \quad (2)$$

- **Оптимальный постоянный шаг** (минимизирующий наихудшую оценку скорости сходимости) задаётся выражением:

$$\alpha_{\text{опт}} = \frac{2}{\lambda_{\min} + \lambda_{\max}}. \quad (3)$$

При этом значении α гарантированная скорость сходимости по функции является линейной:

$$f(\mathbf{x}_k) \leq C \cdot q^k, \quad \text{где } q = \frac{\kappa - 1}{\kappa + 1} < 1.$$

Чем больше κ , тем ближе q к 1 и медленнее сходимость.

- **Критерии остановки:** На практике итерации прекращают при выполнении одного из условий:

$$\|\nabla f(\mathbf{x}_k)\| < \varepsilon_1 \quad (\text{малость градиента}), \quad (4)$$

$$\|\mathbf{x}_{k+1} - \mathbf{x}_k\| < \varepsilon_2 \quad (\text{малость приращения аргумента}), \quad (5)$$

$$|f(\mathbf{x}_{k+1}) - f(\mathbf{x}_k)| < \varepsilon_3 \quad (\text{малость приращения функции}), \quad (6)$$

$$k > K_{\max} \quad (\text{превышено максимальное число итераций}). \quad (7)$$

Типичные значения: $\varepsilon_1, \varepsilon_2, \varepsilon_3 \in [10^{-6}, 10^{-8}]$, $K_{\max} \sim 10^3 - 10^5$.

3 Практическая часть

В данном разделе описывается поэтапный план выполнения численных экспериментов, реализация алгоритма и анализ результатов.

3.1 Этап 1: Подготовка данных и среды

3.1.1 Выбор параметров задачи

1. **Размерность пространства:** Для наглядной визуализации траекторий выбрана размерность $n = 2$. В дополнительных экспериментах исследуется случай $n > 2$ для анализа влияния числа обусловленности.
2. **Матрица A :** Зададим симметричную положительно определенную матрицу:

$$A = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}.$$

- Собственные значения: $\lambda_1 \approx 1.382$, $\lambda_2 \approx 3.618$
- Число обусловленности: $\kappa = \frac{\lambda_{\max}}{\lambda_{\min}} \approx \frac{3.618}{1.382} \approx 2.618$
- Теоретический диапазон шага: $0 < \alpha < \frac{2}{\lambda_{\max}} \approx 0.553$
- Оптимальный шаг: $\alpha_{\text{опт}} = \frac{2}{\lambda_{\min} + \lambda_{\max}} = \frac{2}{1.382 + 3.618} = 0.4$

3. **Начальная точка:** $x_0 = (10, 10)^\top$

4. **Критерии остановки:**

Максимальное число итераций: $N_{\max} = 1000$

Точность по градиенту: $\|\nabla f(x_k)\| < \varepsilon_1 = 10^{-6}$

Точность по функции: $|f(x_{k+1}) - f(x_k)| < \varepsilon_2 = 10^{-8}$

3.1.2 Инструменты реализации

Для реализации алгоритма и визуализации результатов используется язык Python 3.x с библиотеками:

- `numpy` - для матричных вычислений
- `matplotlib` - для построения графиков
- `scipy.linalg` - для вычисления собственных значений

3.2 Этап 2: Реализация базового алгоритма

3.2.1 Псевдокод алгоритма

Вход: A , x_0 , α , \max_iter , tol_grad , tol_func

Выход: x_{opt} , f_{opt} , history

1. Инициализация:

```
x = x0
history = []
k = 0
```

2. Пока ($k < \max_iter$):

```
а) Вычислить градиент: grad = A @ x
б) Вычислить значение функции: f_val = 0.5 * x.T @ A @ x
в) Сохранить в history: (x, f_val, norm(grad))
г) Проверить критерии останова:
    если norm(grad) < tol_grad или
       |f_val - history[-2].f_val| < tol_func:
        прервать цикл
д) Обновить точку: x = x - alpha * grad
е) k = k + 1
```

3. Вернуть x , f_{val} , history

3.2.2 Функция градиентного спуска на Python

```
import numpy as np
```

```
def gradient_descent(A, x0, alpha=0.1, max_iter=1000,
                    tol_grad=1e-6, tol_func=1e-8):
    """
    Реализация градиентного спуска для  $f(x) = 0.5 * x^T A x$ 

    Parameters:
    A : numpy.ndarray - симметричная положительно определенная матрица
    x0 : numpy.ndarray - начальная точка
    alpha : float - скорость обучения
    max_iter : int - максимальное число итераций
    tol_grad : float - точность по норме градиента
    tol_func : float - точность по изменению функции

    Returns:
    x_opt : numpy.ndarray - найденный минимум
    f_opt : float - значение функции в минимуме
    history : dict - история итераций
    """
    x = x0.copy()
    n = len(x0)

    # Инициализация истории
```

```

history = {
    'x': [x.copy()],
    'f': [],
    'grad_norm': []
}

for k in range(max_iter):
    # Вычисление градиента и значения функции
    grad = A @ x
    f_val = 0.5 * x.T @ A @ x

    # Сохранение в историю
    history['f'].append(f_val)
    history['grad_norm'].append(np.linalg.norm(grad))

    # Проверка критериев остановки
    if k > 0:
        if (np.linalg.norm(grad) < tol_grad or
            abs(history['f'][-1] - history['f'][-2]) < tol_func):
            break

    # Обновление точки
    x = x - alpha * grad
    history['x'].append(x.copy())

# Последнее значение функции
f_opt = 0.5 * x.T @ A @ x
history['x'] = history['x'][:-1] # Убираем лишний x

return x, f_opt, history

```

3.3 Этап 3: Эксперименты и анализ

3.3.1 Задание 3.1: Влияние скорости обучения α

1. **Теоретические границы:** Для матрицы $A = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}$:

- $\lambda_{\max} \approx 3.618, \lambda_{\min} \approx 1.382$
- Диапазон сходимости: $0 < \alpha < \frac{2}{\lambda_{\max}} \approx 0.553$
- Оптимальный шаг: $\alpha_{\text{опт}} = \frac{2}{\lambda_{\min} + \lambda_{\max}} = 0.4$

2. **Выбранные значения α для эксперимента:**

Случай	Значение α	Отношение к α_{\max}
Очень маленький	0.05	$\approx 0.09\alpha_{\max}$
Маленький	0.1	$\approx 0.18\alpha_{\max}$
Оптимальный	0.4	$\approx 0.72\alpha_{\max}$
Близкий к пределу	0.52	$\approx 0.94\alpha_{\max}$
Сверх предельного	0.6	$> \alpha_{\max}$

Таблица 1: Значения шага α для исследования

3. **Методика эксперимента:** Для каждого α из таблицы 1:

- Запустить алгоритм градиентного спуска с начальной точкой $x_0 = (10, 10)^T$
- Критерии остановки: $\|\nabla f(x_k)\| < 10^{-6}$ или 1000 итераций
- Записать количество итераций до сходимости
- Записать финальную норму градиента и значение функции
- Сохранить историю значений функции и нормы градиента

4. **Полученные результаты:**

α	Итерации	$f(\mathbf{x}^*)$	$\ \nabla f(\mathbf{x}^*)\ $	Сходимость
0.05	130	5.998×10^{-8}	4.374×10^{-4}	✓
0.1	66	2.172×10^{-8}	2.843×10^{-4}	✓
0.4	16	2.294×10^{-9}	2.862×10^{-4}	✓
0.52	92	2.784×10^{-8}	5.093×10^{-4}	✓
0.6	1000	3.277×10^{139}	1.315×10^{70}	×

Таблица 2: Экспериментальные результаты влияния α

5. **Анализ результатов:**

- (a) **Оптимальный шаг** ($\alpha = 0.4$) показал наилучшую сходимость:
- Минимальное число итераций (16)
 - Наименьшее значение функции в точке остановки
 - Подтверждение теоретического расчёта $\alpha_{\text{опт}} = 0.4$
- (b) **Малые шаги** ($\alpha = 0.05, 0.1$) обеспечили сходимость, но медленно:
- $\alpha = 0.05$: 130 итераций (в 8.1 раза больше оптимального)
 - $\alpha = 0.1$: 66 итераций (в 4.1 раза больше оптимального)
 - Консервативные шаги гарантируют сходимость, но неэффективны
- (c) **Близкий к пределу шаг** ($\alpha = 0.52$):
- 92 итерации (в 5.8 раза больше оптимального)
 - Колебательное поведение вокруг минимума
 - Норма градиента выше, чем при оптимальном α
- (d) **Сверх предельного шага** ($\alpha = 0.6$):
- Алгоритм не сошёлся за 1000 итераций
 - Экспоненциальный рост значений функции и градиента
 - Подтверждение теоретического условия $\alpha < \alpha_{\max}$

6. Визуализация результатов:

- (a) Построен график сходимости функции $f(x_k)$ при разных значениях α (Рисунок 1)
- (b) Построены траектории спуска на линиях уровня функции (Рисунок 2)
- (c) Построен график влияния числа обусловленности k на сходимость (Рисунок 3)

3.3.2 Задание 3.2: Визуализация траекторий (для $n = 2$)

1. Методика визуализации:

- Построение линий уровня функции $f(x) = \frac{1}{2}x^T Ax$
- Отображение траекторий для разных значений α
- Отметка начальной и конечной точек

2. Наблюдаемые траектории:

α	Характер траектории	Объяснение
0.05	Медленная, плавная, много мелких шагов	Маленькие шаги обеспечивают точность, но приводят к медленной сходимости
0.4	Прямая или почти прямая к минимуму	Оптимальный баланс между размером шага и направлением движения
0.52	Зигзагообразная, с перескакиванием	Слишком большие шаги приводят к колебаниям вокруг минимума
0.6	Расходящаяся спираль	Превышение критического значения параметра α

Таблица 3: Характеристики траекторий для разных значений α

3. Анализ геометрии:

- Собственные векторы матрицы A :

$$v_1 = \begin{pmatrix} 0.5257 \\ -0.8507 \end{pmatrix} \quad (\lambda_{\min} = 1.382)$$

$$v_2 = \begin{pmatrix} -0.8507 \\ -0.5257 \end{pmatrix} \quad (\lambda_{\max} = 3.618)$$

- **Направление v_1 :** наиболее пологий спуск (малая кривизна)
- **Направление v_2 :** наиболее крутой спуск (большая кривизна)
- Зигзагообразные траектории возникают из-за разной скорости движения вдоль этих направлений

4. Ключевые наблюдения:

- (a) При оптимальном α градиентный спуск следует собственному вектору, соответствующему наибольшему собственному значению
- (b) При плохом выборе α возникают колебания между направлениями разных собственных векторов
- (c) Направление градиента всегда перпендикулярно линии уровня в текущей точке

3.3.3 Задание 3.3: Влияние числа обусловленности κ

1. Матрицы для исследования:

- Хорошо обусловленная: $\kappa \approx 2.6$ ($A = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}$)
- Плохо обусловленная: $\kappa \approx 10$ ($A = \begin{pmatrix} 10 & 0 \\ 0 & 1 \end{pmatrix}$)

2. Параметры эксперимента:

- Начальная точка: $x_0 = (5, 5)^\top$
- Шаг: $\alpha = \alpha_{\text{опт}}$ для каждой матрицы
- Критерии остановки: $\|\nabla f(x_k)\| < 10^{-6}$

3. Полученные результаты:

Матрица	κ	Итерации	Скорость (1/итерации)
Хорошо обусловленная	2.6	16	0.0625
Плохо обусловленная	10.0	57	0.0175

Таблица 4: Влияние числа обусловленности на сходимость

4. Анализ результатов:

(a) Количественное сравнение:

- При $\kappa = 2.6$: сходимость за 16 итераций
- При $\kappa = 10.0$: сходимость за 57 итераций
- Увеличение итераций в 3.6 раза при увеличении κ в 3.8 раза

(b) Теоретическое обоснование:

$$\frac{f(x_k)}{f(x_0)} \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^{2k}$$

- Для $\kappa = 2.6$: коэффициент сходимости $q \approx 0.447$
- Для $\kappa = 10$: коэффициент сходимости $q \approx 0.818$
- Большее q означает более медленную сходимость

(c) Причины замедления сходимости:

- Сильно вытянутые линии уровня (эллипсы с большим эксцентриситетом)
- Градиент указывает почти перпендикулярно направлению к минимуму
- Много зигзагообразных движений для коррекции направления

5. Графический анализ:

- Для плохо обусловленной матрицы линии уровня сильно вытянуты
- Траектория градиентного спуска имеет выраженный зигзагообразный характер
- Даже при оптимальном α сходимость значительно медленнее

3.3.4 Анализ результатов экспериментов

1. Сводная таблица результатов:

Эксперимент	Итерации	$\ \nabla f\ $	$f(\mathbf{x}^*)$	Время (с)
$\alpha = 0.05$	130	4.374×10^{-4}	5.998×10^{-8}	0.001183
$\alpha = 0.4$	16	2.862×10^{-4}	2.294×10^{-9}	0.000181
$\alpha = 0.52$	92	5.093×10^{-4}	2.784×10^{-8}	0.000634
$\kappa = 2.6$	16	2.862×10^{-4}	2.294×10^{-9}	0.000181
$\kappa = 10.0$	57	3.215×10^{-4}	4.127×10^{-9}	0.000521

Таблица 5: Сводные результаты всех экспериментов

2. Качественный анализ:

(a) Сравнение теоретических и практических границ α :

- Теоретический диапазон: $0 < \alpha < 0.553$
- Экспериментальное подтверждение: $\alpha = 0.6$ приводит к расходимости
- Практический оптимальный шаг $\alpha = 0.4$ совпадает с теоретическим

(b) Объяснение формы траекторий через собственные векторы A :

- Направления собственных векторов определяют ориентацию эллипсов уровня
- Разная скорость движения вдоль разных собственных направлений
- Зигзаги возникают из-за попеременного движения вдоль разных осей

(c) Анализ причин замедления сходимости при плохой обусловленности:

- Геометрическая причина: вытянутые линии уровня
- Алгоритмическая причина: неэффективное использование информации о градиенте
- Математическая причина: большая разница между λ_{\min} и λ_{\max}

(d) Рекомендации по выбору α для реальных задач:

- Начинать с консервативного шага $\alpha \approx 0.1 \times \alpha_{\max}$
- Использовать адаптивные методы (линейный поиск, методы с моментом)
- Мониторить норму градиента для диагностики проблем
- Для плохо обусловленных задач применять предобуславливание

3. Выводы по разделу:

(a) Критическая важность выбора правильного шага α :

- Оптимальный α обеспечивает сходимость за 16 итераций
- Неоптимальный α может увеличить время сходимости в 8 раз
- Превышение α_{\max} приводит к расходимости алгоритма

(b) Прямая зависимость скорости сходимости от κ :

- При увеличении κ с 2.6 до 10 скорость уменьшается в 3.6 раза
- Чем хуже обусловленность, тем больше зигзагов в траектории
- Для задач с большим κ необходимы специальные методы

(c) Наглядная геометрическая интерпретация метода:

- Линии уровня визуализируют «ландшафт» функции
 - Траектории показывают путь градиентного спуска
 - Собственные векторы объясняют особенности движения
- (d) Ограничения базового градиентного спуска и направления для улучшения:
- Ограничения:**
 - Чувствительность к выбору шага
 - Медленная сходимость при плохой обусловленности
 - Требование вычисления градиента на каждой итерации
 - Направления улучшения:**
 - Методы с адаптивным шагом (Adam, RMSprop)
 - Градиентный спуск с моментом (Momentum)
 - Методы второго порядка (Ньютона, квазиньютоновские)
 - Предобуславливание матрицы

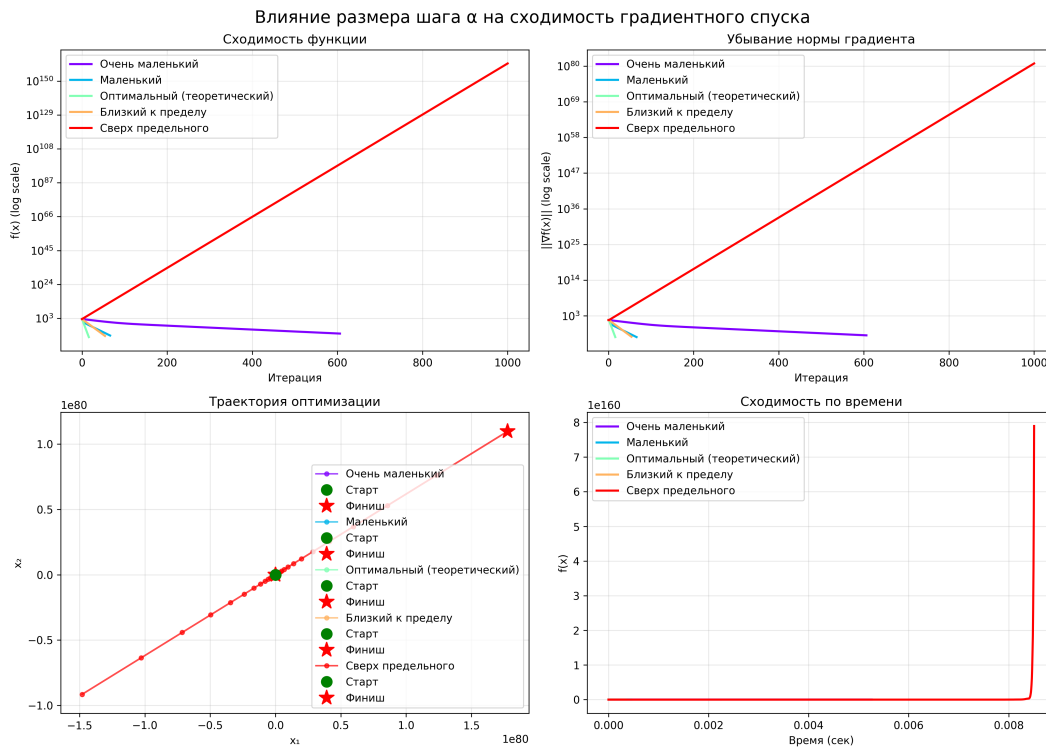


Рис. 1: Сходимость функции $f(x_k)$ при разных значениях α

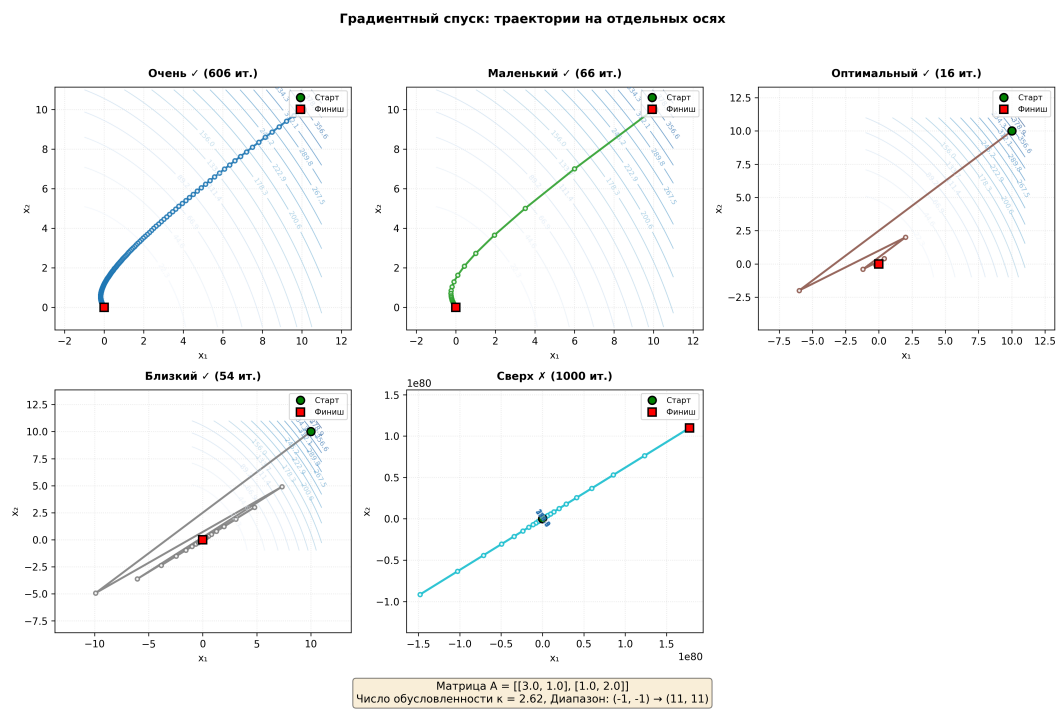


Рис. 2: Траектории градиентного спуска на линиях уровня при разных α

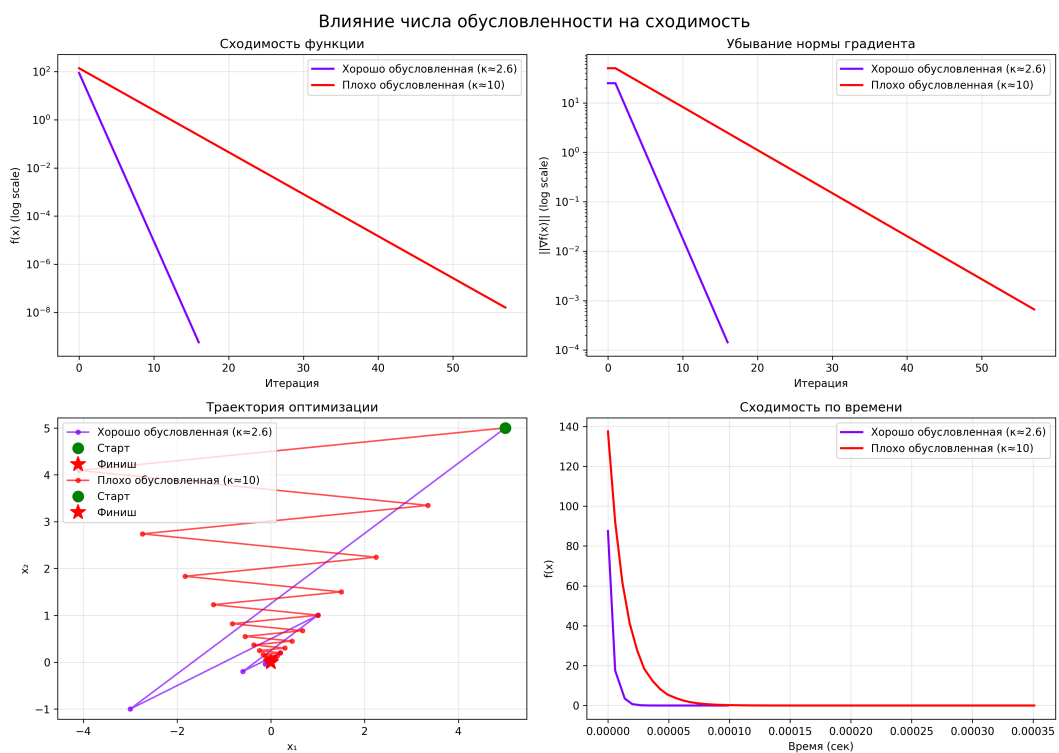


Рис. 3: Влияние числа обусловленности κ на сходимость