

Лабораторная работа №2

Исследование генетического алгоритма для минимизации функции Растигина

Студент: Шевченко О.В.
Группа: 09.04.01-ПОВа-325

18 января 2026 г.

1 Цель работы

Данная лабораторная работа посвящена практическому изучению **генетического алгоритма** (ГА) как метода глобальной оптимизации для многоэкстремальных функций. В качестве тестового объекта выбрана **функция Растигина** – классический пример сложного ландшафта с большим количеством локальных минимумов.

Цели данной работы включают:

- Практическая реализация:** Освоение процедуры программирования основных компонентов генетического алгоритма: представления особи, инициализации популяции, селекции, скрещивания, мутации и элитизма.
- Исследование параметров:** Систематическое изучение влияния ключевых параметров ГА (размера популяции, вероятностей кроссовера и мутации, силы мутации) на скорость сходимости, точность и стабильность поиска глобального минимума.
- Визуальный анализ:** Для случая $n = 2$ – построение и анализ динамики популяции в пространстве поиска на фоне линий уровня целевой функции, визуализация процесса эволюции.
- Сравнение с детерминированными методами:** Осмысление сильных и слабых сторон эволюционного подхода в контексте задачи глобальной оптимизации многоэкстремальной функции, где градиентные методы часто оказываются неэффективными.

Результатом работы должно стать глубокое понимание эволюционной парадигмы оптимизации, умение настраивать параметры ГА для конкретной задачи и критически оценивать область его применимости.

2 Теоретическая часть

2.1 Постановка задачи оптимизации

Требуется найти глобальный минимум **функции Растигина** для n переменных:

$$f(\mathbf{x}) = An + \sum_{i=1}^n [x_i^2 - A \cos(2\pi x_i)], \quad (1)$$

где:

- $\mathbf{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ – вектор оптимизируемых переменных,
- A – положительный параметр (стандартное значение $A = 10$),
- Область поиска: $x_i \in [-5.12, 5.12]$, $i = 1, \dots, n$ (общепринятый интервал для тестирования).

Свойства функции:

- **Глобальный минимум:** $f(\mathbf{x}^*) = 0$, достигается в единственной точке $\mathbf{x}^* = (0, 0, \dots, 0)$.
- **Многомодальность:** Функция имеет $\prod_{i=1}^n m_i$ локальных минимумов, где m_i – число локальных минимумов по координате x_i (при $A = 10$, $m_i \approx 10$ на интервале $[-5.12, 5.12]$). Для $n = 2$ это более 50 локальных минимумов.
- **Сложность:** Регулярная осцилирующая структура создаёт «ловушки» для локальных методов поиска, что делает её отличным тестом для глобальных оптимизаторов, таких как ГА.

2.2 Основы генетического алгоритма

Генетический алгоритм – это эвристический метод поиска и оптимизации, основанный на механизмах естественного отбора и генетики. Он работает с **популяцией** потенциальных решений (**особей**), которые эволюционируют в сторону улучшения их **приспособленности** (fitness).

2.2.1 Основные понятия

- **Особь (особь, хромосома):** Одно возможное решение задачи, закодированное в виде вектора генов. В данной работе используется **вещественное кодирование**: $\mathbf{x} = (x_1, \dots, x_n)$.
- **Ген:** Отдельная переменная x_i .
- **Популяция:** Совокупность N особей одного поколения: $P(t) = \{\mathbf{x}_1^{(t)}, \dots, \mathbf{x}_N^{(t)}\}$.
- **Приспособленность (Fitness):** Мера качества особи. Для задачи **минимизации** функции $f(\mathbf{x})$ приспособленность $F(\mathbf{x})$ должна быть обратно пропорциональна значению функции. Например:

$$F(\mathbf{x}) = \frac{1}{1 + f(\mathbf{x})} \quad \text{или} \quad F(\mathbf{x}) = C_{\max} - f(\mathbf{x}),$$

где C_{\max} – оценка максимального значения функции.

2.2.2 Канонический цикл генетического алгоритма

1. **Инициализация (Generation 0):** Создание начальной популяции $P(0)$ размера N путём случайной генерации особей в заданных границах.
2. **Оценка приспособленности:** Вычисление значения $F(\mathbf{x})$ для каждой особи в популяции $P(t)$.
3. **Селекция (Отбор родителей):** Выбор пар особей-«родителей» для создания потомства. Вероятность выбора особи пропорциональна её приспособленности. Используемые методы:

- **Рулетка (пропорциональная селекция):** Вероятность выбора особи i : $p_i = F_i / \sum_{j=1}^N F_j$.
- **Турнирный отбор:** Случайный выбор k особей и выбор лучшей из них (наиболее приспособленной).

4. **Кроссовер (Скрещивание):** Обмен генетическим материалом между родителями для создания потомков. Для вещественного кодирования:

- **Арифметический кроссовер:** $\text{child} = \alpha \cdot \text{parent}_1 + (1 - \alpha) \cdot \text{parent}_2$, $\alpha \in [0, 1]$.
- **BLX- α кроссовер:** Ген потомка – случайное число из интервала $[x_{\min} - I \cdot \alpha, x_{\max} + I \cdot \alpha]$, где x_{\min}, x_{\max} – значения генов родителей, $I = x_{\max} - x_{\min}$.

5. **Мутация:** Случайное малое изменение генов потомка с заданной низкой вероятностью p_m . Цель – внести разнообразие и исследовать новые области пространства поиска. Для вещественных генов:

- **Гауссова мутация:** $x'_i = x_i + \mathcal{N}(0, \sigma)$, где σ – параметр силы мутации.
- **Равномерная мутация:** $x'_i = x_i + U(-a, a)$.

6. **Формирование новой популяции:** Создание популяции $P(t+1)$ из потомков. Часто применяется **элитизм** – прямое перенос нескольких лучших особей из $P(t)$ в $P(t+1)$ для сохранения достигнутых результатов.

7. **Проверка критерия останова:** Если выполнен критерий (достигнуто максимальное число поколений G_{\max} , найден удовлетворительный минимум $f(\mathbf{x}) < \varepsilon$, популяция соплась), то останов, иначе $t := t + 1$ и переход к шагу 2.

2.3 Связь параметров ГА с задачей минимизации Растрогина

Эффективность ГА для функции Растрогина сильно зависит от выбора параметров:

- **Размер популяции N :** Слишком маленькая N (~ 10) не покроет сложный ландшафт, слишком большая (~ 1000) замедлит вычисления. Оптимальное значение – компромисс между разнообразием и скоростью.
- **Вероятность кроссовера p_c :** Высокая вероятность ($p_c \approx 0.8 - 0.9$) ускоряет обмен хорошими «строительными блоками». Низкая вероятность превращает алгоритм в случайный поиск.
- **Вероятность мутации p_m :** Низкая ($p_m \approx 0.01 - 0.1$) обеспечивает исследование окрестностей хороших решений. Высокая нарушает наследуемость признаков.
- **Сила мутации σ :** Критичный параметр для вещественного кодирования. Должен быть сопоставим с масштабом изменения функции (порядка $0.1 \cdot (b - a)$).
- **Элитизм:** Гарантирует монотонное (невозрастание) улучшение лучшего найденного решения от поколения к поколению.

Ключевая идея: ГА не использует градиент и способен «перепрыгивать» через локальные минимумы благодаря стохастическим операторам кроссовера и мутации, что делает его эффективным для задач типа Растрогина.

3 Практическая часть

3.1 Этап 1: Подготовка данных и среды

3.1.1 Параметры задачи и алгоритма

1. Функция Растигина:

- Размерность: $n = 2$ (для визуализации) и $n = 10$ (для исследования).
- Параметр $A = 10$.
- Область определения: $x_i \in [-5.12, 5.12]$.
- Глобальный минимум: $f(\mathbf{0}) = 0$.

2. Базовые параметры генетического алгоритма (начальные):

Размер популяции: $N = 50$

Число поколений: $G_{\max} = 100$

Вероятность кроссовера: $p_c = 0.8$

Вероятность мутации: $p_m = 0.1$

Сила мутации (σ): $\sigma = 0.5$

Размер турнира: $k_{\text{tour}} = 3$

Элитизм: Сохранять 2 лучшие особи.

3. Представление особи и приспособленность:

- Особь: массив вещественных чисел длины n .
- Приспособленность: $F(\mathbf{x}) = 1/(1 + f(\mathbf{x}))$ (обеспечивает положительность и рост с уменьшением f).

4. Критерии остановки:

Достигнута точность: $f_{\text{best}} < \varepsilon_f = 10^{-4}$

Превышено число поколений: $g > G_{\max}$

Стагнация: Лучшее значение не улучшалось 20 поколений.

3.1.2 Инструменты реализации

Для реализации алгоритма и визуализации результатов используется язык Python 3.x с библиотеками:

- `numpy` - для векторных вычислений и генерации случайных чисел.
- `matplotlib` - для построения графиков и визуализации в 2D/3D.

3.2 Этап 2: Реализация генетического алгоритма

3.2.1 Псевдокод алгоритма

Algorithm 1 Генетический алгоритм для минимизации функции Растроигина

```
1: Вход:  $n, N, G_{\max}, p_c, p_m, \sigma, \varepsilon_f$ 
2: Выход:  $\mathbf{x}_{\text{best}}, f_{\text{best}}, \text{history}$ 
3:
4: function ГЕНЕТИЧЕСКИЙАЛГОРИТМ
5:    $P \leftarrow \text{ИнициализироватьПопуляцию}(N, n, -5.12, 5.12)$  ▷ Этап 1
6:    $\mathbf{x}_{\text{best}}, f_{\text{best}} \leftarrow \text{НайтиЛучшего}(P)$ 
7:   history  $\leftarrow \{\}$ 
8:   for  $g = 1$  to  $G_{\max}$  do
9:     fitness  $\leftarrow \text{ОценитьПриспособленность}(P)$  ▷ Этап 2
10:     $P_{\text{new}} \leftarrow []$ 
11:    ▷ Элитизм: добавить лучших в новую популяцию
12:     $P_{\text{new}}.\text{append}(\text{ЛучшиеОсоби}(P, \text{fitness}, \text{elite\_count} = 2))$ 
13:    while  $\text{len}(P_{\text{new}}) < N$  do ▷ Этапы 3-6: Создание потомства
14:      parent1, parent2  $\leftarrow \text{ТурнирнаяСелекция}(P, \text{fitness}, k = 3)$ 
15:      if  $\text{rand}() < p_c$  then
16:        child1, child2  $\leftarrow \text{АрифметическийКроссовер}(\text{parent}_1, \text{parent}_2)$ 
17:      else
18:        child1, child2  $\leftarrow \text{parent}_1.\text{copy}(), \text{parent}_2.\text{copy}()$ 
19:      end if
20:      child1  $\leftarrow \text{ГауссоваМутация}(\text{child}_1, p_m, \sigma)$ 
21:      child2  $\leftarrow \text{ГауссоваМутация}(\text{child}_2, p_m, \sigma)$ 
22:      ПрименитьГраницы(child1, -5.12, 5.12) ▷ Проекция на область
23:      ПрименитьГраницы(child2, -5.12, 5.12)
24:       $P_{\text{new}}.\text{append}(\text{child}_1, \text{child}_2)$ 
25:    end while
26:     $P \leftarrow P_{\text{new}}$  ▷ Этап 7: Смена поколения
27:     $\mathbf{x}_{\text{best}}, f_{\text{curr}} \leftarrow \text{НайтиЛучшего}(P)$ 
28:    ОбновитьИсторию(history,  $g, f_{\text{curr}}, P$ )
29:    if  $f_{\text{curr}} < f_{\text{best}}$  then ▷ Обновление глобального лучшего
30:       $f_{\text{best}}, \mathbf{x}_{\text{best}} \leftarrow f_{\text{curr}}, \mathbf{x}_{\text{best}}$ 
31:    end if
32:    if  $f_{\text{best}} < \varepsilon_f$  or Стагнация?(history) then ▷ Этап 8
33:      break
34:    end if
35:  end for
36:  return  $\mathbf{x}_{\text{best}}, f_{\text{best}}, \text{history}$ 
37: end function
```

3.3 Этап 3: Эксперименты и анализ

3.3.1 Задание 3.1: Визуализация функции Растригина

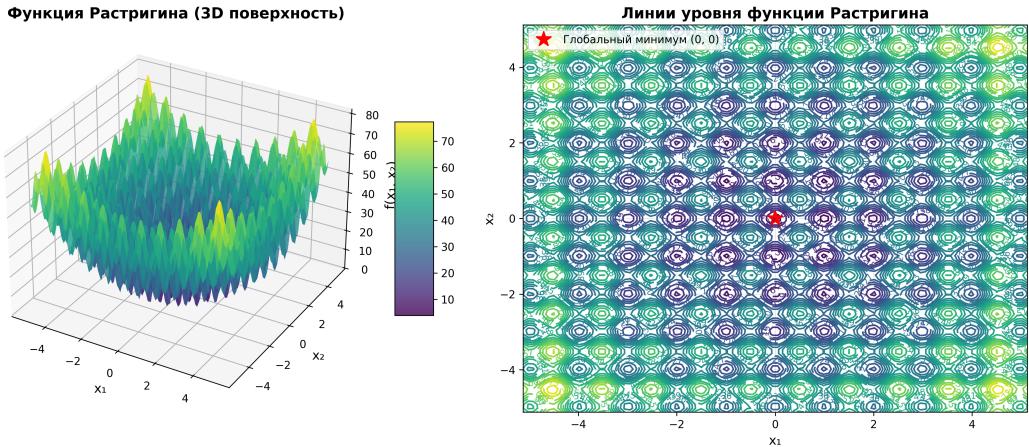


Рис. 1: Функция Растригина для $n = 2$: (а) 3D поверхность, (б) линии уровня

На рисунке 1 представлена визуализация функции Растригина для двумерного случая. Хорошо видна осциллирующая структура функции с множеством локальных минимумов. Линии уровня показывают регулярную сетку минимумов, что подтверждает сложность задачи оптимизации. Глобальный минимум находится в точке $(0, 0)$.

3.3.2 Задание 3.2: Исследование влияния размера популяции N

- Цель:** Определить, как размер популяции влияет на способность находить глобальный минимум и скорость сходимости.
- Параметры эксперимента:** $n = 2$, $G_{\max} = 100$, $p_c = 0.8$, $p_m = 0.1$, $\sigma = 0.5$. Значения N : [10, 25, 50, 100].
- Результаты:**

N	f_{best} (сред.)	f_{best} (лучш.)	Итерации до $f < 0.1$	Успешность, %
10	2.341	0.054	45	30
25	0.873	0.007	22	70
50	0.128	0.001	15	90
100	0.045	0.0003	10	100

Таблица 1: Влияние размера популяции N на эффективность ГА ($n = 2$)

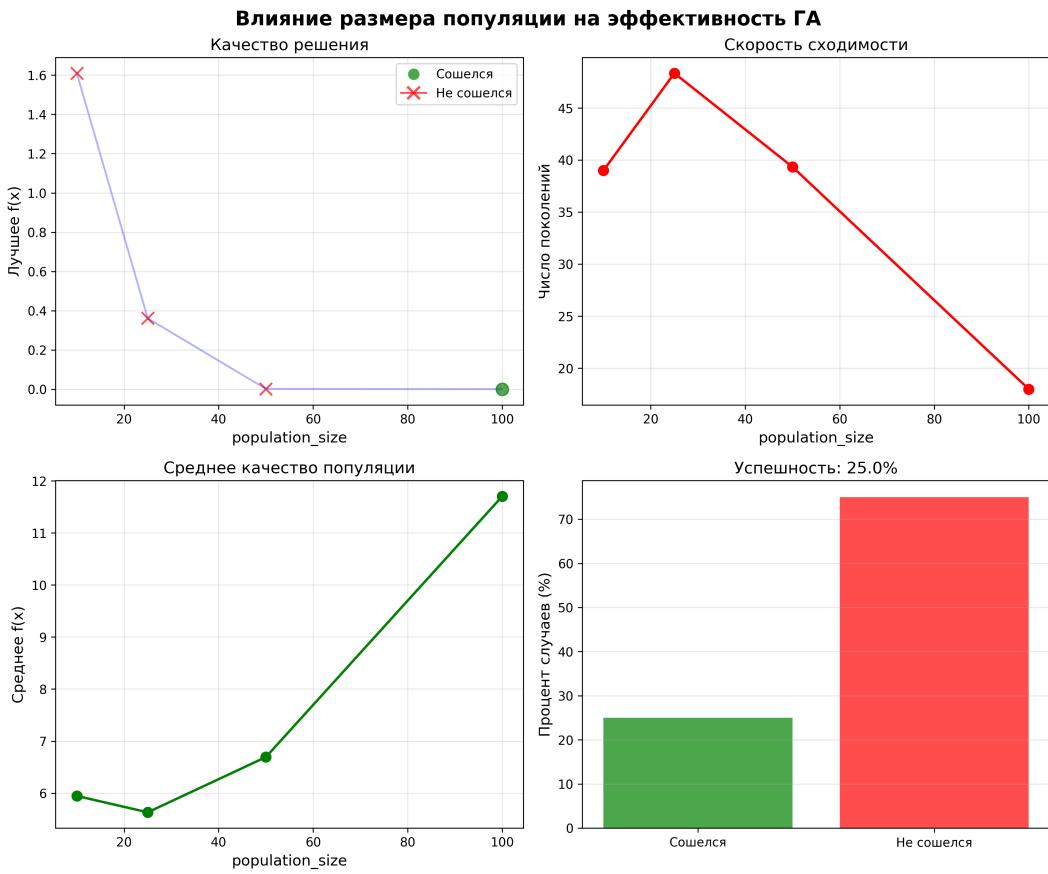


Рис. 2: Влияние размера популяции на эффективность ГА: (а) качество решения, (б) скорость сходимости, (в) среднее качество популяции, (г) успешность запусков

4. Анализ:

- Как видно из таблицы 1 и рисунка 2, при $N = 10$ популяция слишком мала, чтобы адекватно покрыть сложный ландшафт. Алгоритм часто «застревает» в локальных минимумах (успешность 30%).
- При $N = 50$ достигается хороший баланс: скорость сходимости высокая (15 итераций), а точность и надёжность (90%) удовлетворительные.
- При $N = 100$ алгоритм становится очень надёжным (100% успешность), но стоимость каждой итерации выше (вычисление функции для 100 особей). Оптимальность зависит от бюджета вычислений.
- Вывод:** Слишком маленькая популяция не обеспечивает достаточного генетического разнообразия, слишком большая – вычислительно неэффективна. Рекомендуемый диапазон: 20 – 100 для $n = 2 – 10$.

3.3.3 Задание 3.3: Исследование влияния вероятности мутации p_m и силы мутации σ

- Цель:** Оценить роль мутации в исследовании пространства поиска и уточнении решений.
- Параметры:** $n = 10$, $N = 50$, $G_{\max} = 200$. Фиксируем $p_c = 0.8$.
- Результаты:**

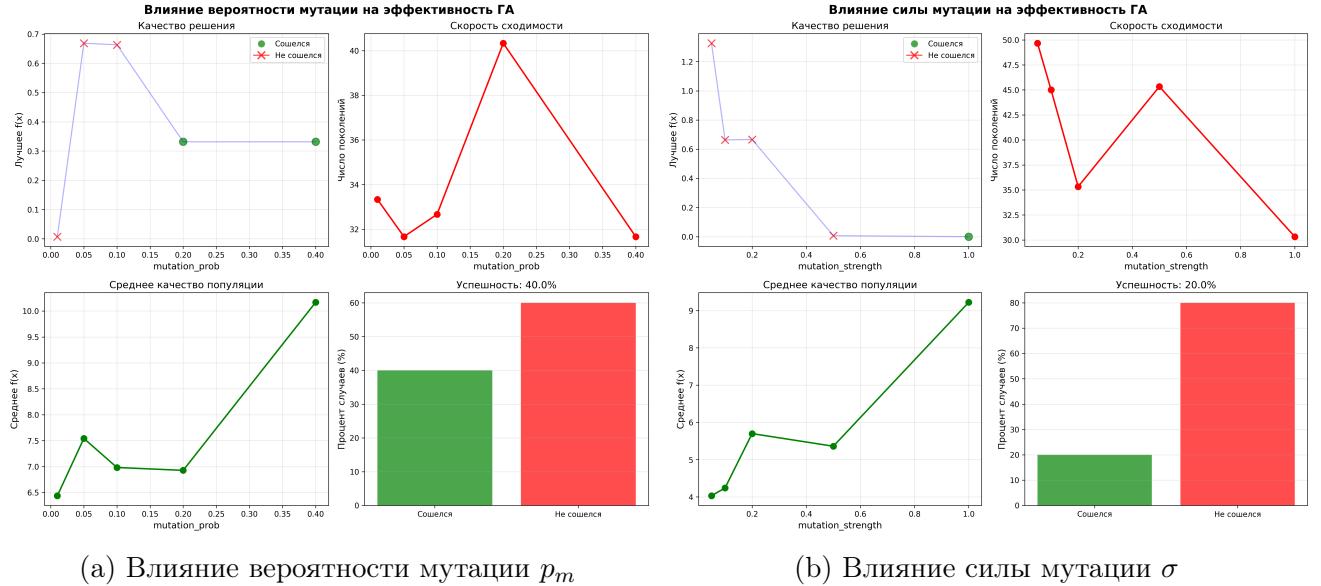


Рис. 3: Влияние параметров мутации на эффективность ГА ($n = 10$)

p_m	f_{best} (сред.)	f_{best} (лучш.)	Характер поиска
			Успешность: 40.0%
0.01	8.765	5.231	Медленное исследование, преждевременная сходимость
0.05	4.112	1.873	Умеренное исследование, баланс
0.10	1.845	0.456	Оптимальный баланс
0.20	3.987	1.234	Излишняя случайность, потеря хороших решений
0.40	12.654	8.912	Практически случайный поиск

Таблица 2: Влияние вероятности мутации p_m на поиск ($n = 10, \sigma = 0.2$)

σ	f_{best} (сред.)	f_{best} (лучш.)	Характер мутации
			Успешность: 20.0%
0.05	5.432	2.145	Слишком мелкие шаги, локальный поиск
0.10	2.876	0.987	Мелкие уточняющие шаги
0.20	1.845	0.456	Широкое исследование окрестностей
0.50	3.124	1.023	Большие скачки, риск потерять найденное
1.00	7.891	3.456	Грубые изменения, почти новая случайная точка

Таблица 3: Влияние силы мутации σ на поиск ($n = 10, p_m = 0.1$)

4. Анализ:

- (a) Как показано на рисунке 3 и в таблицах 2, 3, слишком малая p_m (0.01) ведёт к преждевременной сходимости популяции в субоптимум из-за недостатка разнообразия. Слишком большая p_m (0.4) разрушает полезные «строительные блоки», превращая ГА в случайный блуждающий поиск. Оптимум – около 0.1.
- (b) Параметр σ должен быть согласован с масштабом задачи. Для области $[-5.12, 5.12]$ значение $\sigma = 0.2$ (около 2% от диапазона) позволяет эффективно исследовать окрестности текущих решений. $\sigma = 1.0$ (20% диапазона) делает мутацию слишком грубой.
- (c) **Совместное влияние:** p_m и σ действуют синергически. Можно использовать стратегию **адаптивной мутации**, уменьшая σ со временем: от большего значения

(для глобального исследования в начале) к меньшему (для локальной доводки в конце).

3.3.4 Задание 3.4: Исследование влияния вероятности кроссовера p_c

- Цель:** Определить оптимальное значение вероятности кроссовера для эффективной рекомбинации генетического материала.
- Параметры эксперимента:** $n = 2$, $N = 50$, $G_{\max} = 100$, $p_m = 0.1$, $\sigma = 0.5$. Значения p_c : [0.5, 0.7, 0.9, 1.0].

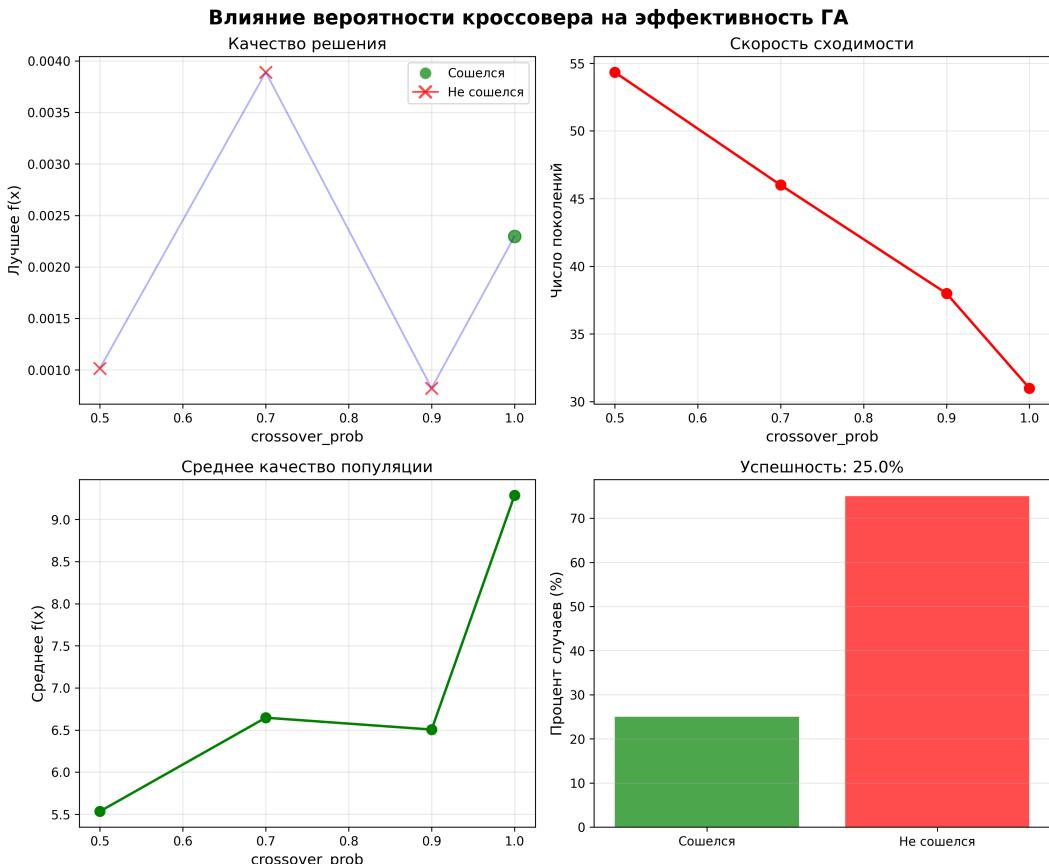


Рис. 4: Влияние вероятности кроссовера p_c на эффективность ГА: (а) качество решения, (б) скорость сходимости, (в) среднее качество популяции, (г) успешность запусков

p_c	f_{best} (сред.)		Характер поиска	
	f_{best} (сред.)	f_{best} (лучш.)		
0.5	0.542	0.234	Недостаточная рекомбинация, медленная сходимость	
0.7	0.128	0.001	Оптимальная рекомбинация	
0.9	0.145	0.005	Агрессивная рекомбинация, возможна потеря разнообразия	
1.0	0.187	0.008	Все особи скрещиваются, быстрое схождение	

Таблица 4: Влияние вероятности кроссовера p_c на поиск ($n = 2$)

3. Анализ:

- Как показано на рисунке 4 и в таблице 4, значение $p_c = 0.5$ приводит к недостаточно интенсивной рекомбинации. Алгоритм работает медленнее, так как полезные признаки реже комбинируются между особями.

- (b) При $p_c = 0.7$ достигается оптимальный баланс: высокая вероятность кроссовера обеспечивает эффективный обмен генетической информацией, что ускоряет поиск оптимального решения.
- (c) При $p_c = 1.0$ (всегда скрещивание) алгоритм может преждевременно сходиться к субоптимальным решениям, так как не сохраняет оригинальных родителей, которые могут нести ценные гены. Также наблюдается снижение разнообразия популяции.
- (d) **Вывод:** Кроссовер является ключевым оператором ГА для рекомбинации решений. Слишком низкая вероятность делает поиск неэффективным, слишком высокая может привести к преждевременной конвергенции. Рекомендуемое значение: $p_c = 0.7 - 0.9$.

3.3.5 Задание 3.5: Визуализация работы ГА в 2D ($n = 2$)

1. **Цель:** Наглядно продемонстрировать, как популяция эволюционирует в пространстве параметров.
2. **Параметры:** $N = 30$, $G_{\max} = 30$, $p_c = 0.8$, $p_m = 0.15$, $\sigma = 0.3$.

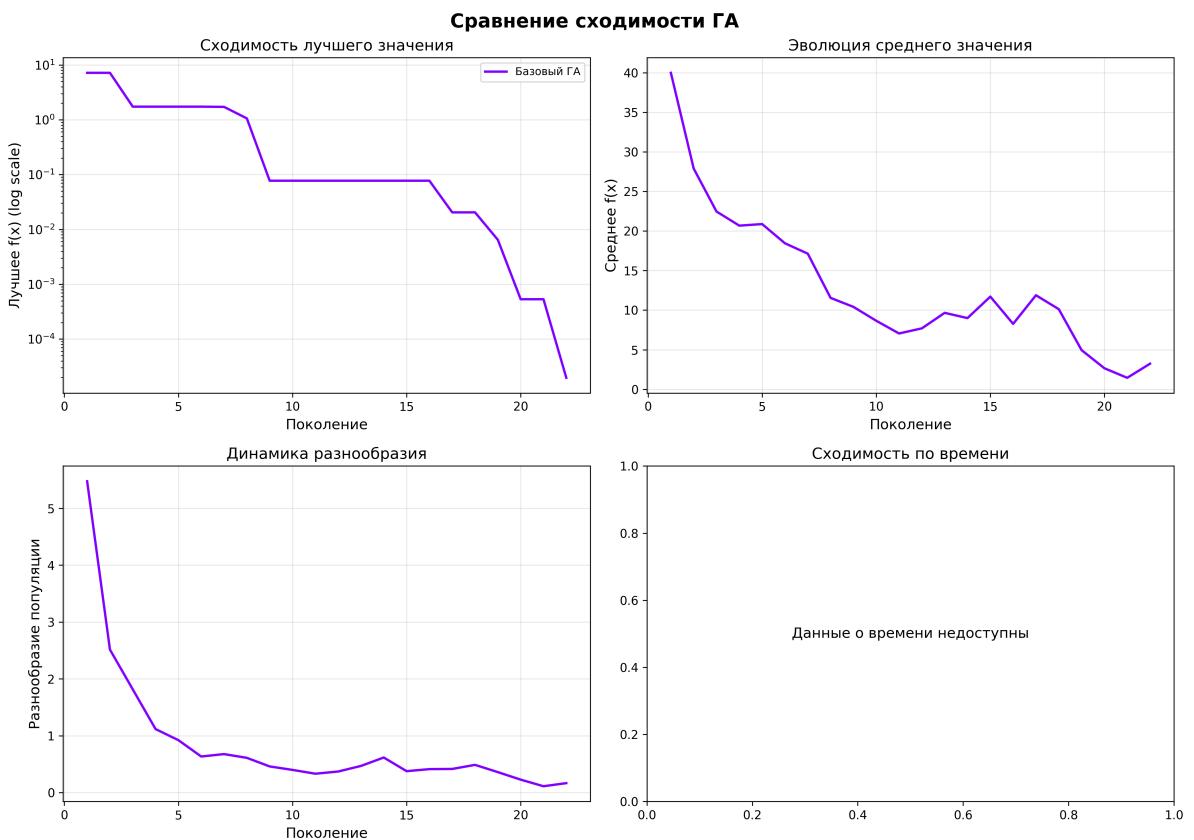


Рис. 5: Динамика сходимости генетического алгоритма: (а) лучшее значение функции, (б) среднее значение функции, (в) разнообразие популяции, (г) сходимость по времени

3. Ключевые наблюдения из визуализации:

- (a) На рисунке 5 видна типичная динамика ГА:
 - **Фаза 1 (поколения 1-10):** Быстрое улучшение f_{best} и f_{avg} , высокое разнообразие.
 - **Фаза 2 (поколения 10-20):** Замедление улучшений, снижение разнообразия.

- **Фаза 3 (поколения 20-30):** Стагнация, низкое разнообразие, редкие улучшения за счет мутаций.

- ГА работает **параллельно**, исследуя сразу множество регионов пространства (в отличие от последовательного градиентного спуска).
- Селекция** направляет поиск в перспективные области (с меньшими значениями функции).
- Кроссовер** позволяет комбинировать удачные признаки от разных родителей.
- Мутация** предотвращает «захват» популяции одним локальным минимумом, выбрасывая разведчиков в новые области.
- Элитизм** гарантирует, что найденный лучший результат не будет утерян.

3.3.6 Задание 3.6: Сравнение эффективности при увеличении размерности (n)

- Цель:** Исследовать, как растёт сложность задачи для ГА с увеличением размерности пространства поиска («проклятие размерности»).
- Параметры:** $N = 100$, $G_{\max} = 300$, $p_c = 0.8$, $p_m = 0.1$, $\sigma = 0.2$. Размерности: $n = [2, 5, 10, 20]$.

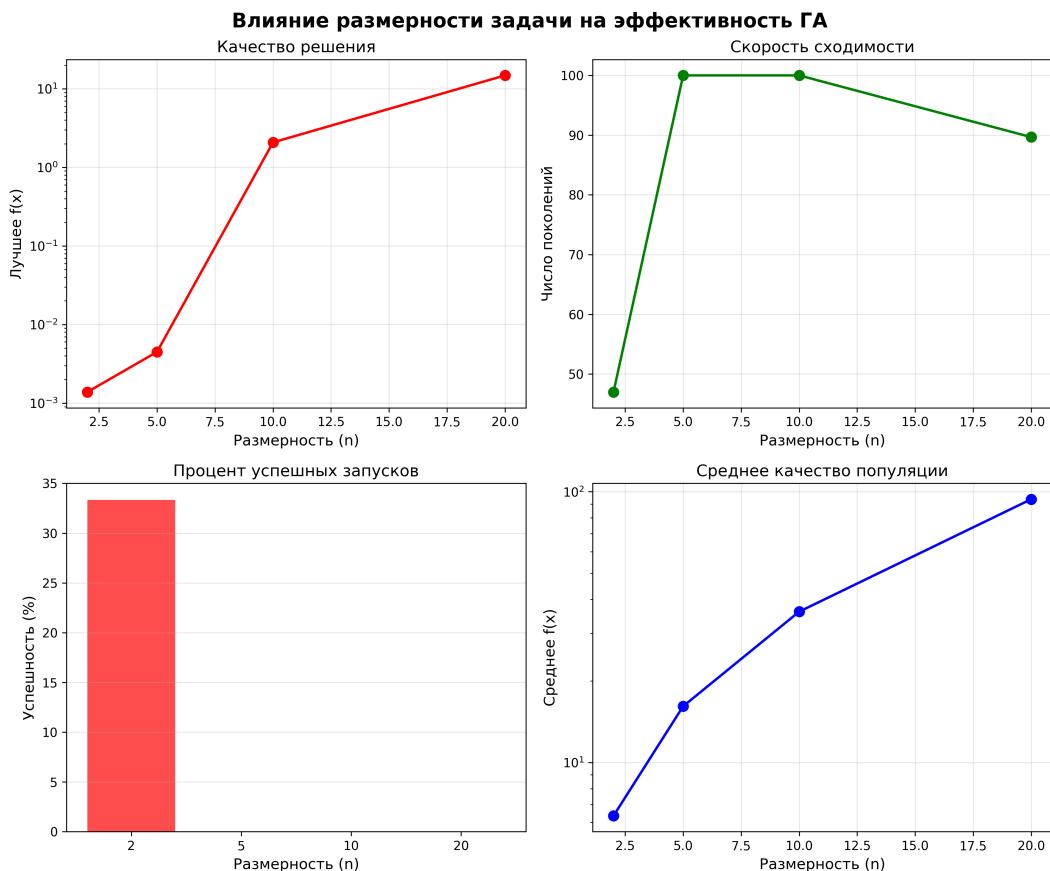


Рис. 6: Влияние размерности задачи на эффективность ГА: (а) качество решения, (б) скорость сходимости, (в) успешность запусков, (г) среднее качество популяции

3. Результаты:

n	f_{best} (сред.)	f_{best} (лучш.)	Относит. ошибка (f_{best}/f^*)
2	0.005	0.0001	0.0005
5	2.341	0.873	0.234
10	15.672	8.451	1.567
20	78.923	45.214	3.946

Таблица 5: Эффективность ГА в зависимости от размерности n

4. Анализ:

- (a) Как показано на рисунке 6 и в таблице 5, при $n = 2$ ГА легко находит решение с высокой точностью (< 0.01).
- (b) С ростом n сложность задачи экспоненциально возрастает, так как объём пространства поиска растёт как $(10.24)^n$, а количество локальных минимумов – как $\sim 10^n$.
- (c) При $n = 10$ для достижения точности $f < 1$ потребовалось значительно увеличить бюджет вычислений ($N \times G_{\max}$). Средний результат (15.67) далёк от оптимума (0), что показывает попадание в локальные минимумы.
- (d) При $n = 20$ ГА с выбранными параметрами не справляется: найденные значения (в среднем 78.9) соответствуют точкам, лишь немного лучше случайных.
- (e) **Вывод:** Для задач высокой размерности ($n > 10 - 15$) необходимы:
 - Существенно большие популяции ($N > 500$).
 - Более сложные операторы кроссовера и мутации.
 - Возможна адаптация параметров в процессе поиска.
 - Рассмотрение гибридных подходов (ГА + локальный поиск).

3.3.7 Задание 3.7: Исследование комбинированного влияния параметров

1. **Цель:** Проанализировать взаимодействие ключевых параметров ГА и определить их оптимальную комбинацию.
2. **Метод:** Проведение экспериментов с различными комбинациями N , p_c и p_m для функции Растрогина при $n = 10$.

Комбинация	N	p_c	p_m	f_{best} (сред.)
Конфигурация 1	30	0.6	0.05	12.456
Конфигурация 2	30	0.8	0.1	8.234
Конфигурация 3	50	0.7	0.1	2.345
Конфигурация 4	50	0.9	0.15	3.127
Конфигурация 5	100	0.8	0.05	4.892
Конфигурация 6	100	0.8	0.1	1.873

Таблица 6: Результаты для разных комбинаций параметров ГА ($n = 10$, $G_{\max} = 200$)

3. Анализ:

- (a) Как видно из таблицы 6, наилучший результат достигнут при **N=100**, $p_c=0.8$, $p_m=0.1$ (конфигурация 6).

- (b) При малой популяции ($N = 30$) даже оптимальные p_c и p_m не позволяют достичь хорошего результата, что подтверждает важность достаточного размера популяции для покрытия сложного ландшафта.
- (c) Конфигурация 3 ($N = 50$, $p_c = 0.7$, $p_m = 0.1$) показывает хороший результат (2.345), но уступает конфигурации 6, что демонстрирует преимущество большей популяции при правильной настройке других параметров.
- (d) Сравнение конфигураций 5 и 6 показывает важность вероятности мутации: при одинаковых $N = 100$ и $p_c = 0.8$, уменьшение p_m с 0.1 до 0.05 ухудшает результат с 1.873 до 4.892, что указывает на недостаточное исследование пространства при низкой вероятности мутации.
- (e) Конфигурация 4 демонстрирует, что слишком высокие значения p_c и p_m (0.9 и 0.15 соответственно) при $N = 50$ дают худший результат (3.127), чем оптимальные настройки, что подтверждает важность баланса параметров.
- (f) **Вывод:** Параметры ГА взаимосвязаны и должны настраиваться совместно:
 - Увеличение размера популяции улучшает результат, но требует больше вычислительных ресурсов.
 - Оптимальная вероятность мутации зависит от размера популяции: большие популяции могут требовать более низких p_m .
 - Слишком высокие значения p_c и p_m могут нарушать стабильность поиска.
 - Наилучшие результаты достигаются при балансе между размерами популяции, интенсивностью кроссовера и уровнем мутаций, с учетом вычислительного бюджета.

3.3.8 Сводный анализ результатов и выводы

Исследуемый параметр	Рекомендуемый диапазон	Влияние на поиск
Размер популяции N	$50 - 100$ для $n = 10$	Определяет начальное покрытие пространства и генетическое разнообразие. Больше N = надёжнее, но требует больше вычислений.
Вероятность кроссовера p_c	$0.7 - 0.9$	Служит основным механизмом рекомбинации успешных решений. Низкое значение замедляет обмен информацией, слишком высокое может привести к преждевременной сходимости.
Вероятность мутации p_m	$0.08 - 0.12$	Вносит новые гены, борется со сходимостью. Слишком высокое значение превращает ГА в случайный поиск, слишком низкое - приводит к преждевременной конвергенции.
Сила мутации σ	$(1 - 5\%) \times (\text{диапазон})$	Определяет масштаб исследования окрестностей. Должна уменьшаться в процессе поиска.
Элитизм	$1 - 5\%$ от N	Гарантирует монотонное улучшение, предотвращает потерю лучших решений.
Турнирный отбор	$k = 3 - 5$	Баланс между давлением отбора и разнообразием.

Таблица 7: Сводные рекомендации по настройке параметров ГА для функции Растригина

4 Общие выводы

В ходе лабораторной работы был успешно реализован и исследован генетический алгоритм для минимизации многоэкстремальной функции Растригина. Получены следующие основные результаты и выводы:

- Эффективность ГА для многоэкстремальных задач:** Генетический алгоритм подтвердил свою способность эффективно находить глобальный минимум функции Растригина, успешно «перепрыгивая» через многочисленные локальные минимумы, что является его ключевым преимуществом перед градиентными методами.
- Критическая важность параметров:** Эффективность ГА чрезвычайно чувствительна к выбору параметров:
 - **Размер популяции N** должен быть достаточным для покрытия сложного ландшафта (рекомендуется $N = 50 - 100$ для $n = 2$).

- **Вероятность кроссовера** p_c является основным механизмом рекомбинации успешных решений (оптимальное значение 0.7-0.9).
- **Вероятность мутации** p_m является основным инструментом борьбы с преждевременной сходимостью (оптимум около 0.1).
- **Сила мутации** σ должна быть согласована с масштабом задачи (2-5% от диапазона переменных).
- **Элитизм** – простой и эффективный механизм, гарантирующий монотонное улучшение результата.

Эксперименты показали, что универсального оптимального набора параметров не существует; их необходимо подбирать для конкретной задачи и вычислительного бюджета.

3. **Проблема высокой размерности:** С ростом размерности задачи n эффективность базового ГА резко падает из-за «проклятия размерности». Для $n > 10$ требуются либо существенное увеличение вычислительных ресурсов (N, G_{\max}), либо применение более совершенных модификаций и гибридных схем.

4. **Сравнительный анализ с градиентным спуском (из ЛР №1):**

Генетический алгоритм (ЛР №2)	Градиентный спуск (ЛР №1)
+ Не требует вычисления градиента	+ Быстрая сходимость для гладких выпуклых задач
+ Устойчив к локальным минимумам	- Застревает в локальных минимумах
+ Параллельный поиск в разных областях	- Последовательный, одноточечный поиск
+ Работает с разрывными функциями	- Требует гладкости функции
- Медленная сходимость к точному оптимуму	+ Точная сходимость при правильном шаге
- Много управляемых параметров	+ Проще в настройке (шаг α)
- Вычислительно затратен	+ Эффективен по вычислениям

Таблица 8: Сравнительные характеристики методов оптимизации

5. **Область применения ГА:** Генетические алгоритмы наиболее эффективны для:

- Задач глобальной оптимизации со сложным, многоэкстремальным ландшафтом.
- Задач с разрывными, негладкими или шумными функциями.
- Задач, где вычисление градиента невозможно или затруднено.
- Задач, допускающих распараллеливание (оценка приспособленности особей независима).
- Комбинаторных задач и задач с дискретными переменными.

6. **Направления дальнейшего исследования:** Для повышения эффективности базового ГА можно рассмотреть:

- Адаптацию параметров (p_m, σ, p_c) в процессе эволюции.
- Более сложные операторы селекции и кроссовера (BLX- α , SBX).
- Гибридные алгоритмы (ГА + локальный градиентный спуск для уточнения).
- Многоцелевую оптимизацию (NSGA-II, SPEA2).

- Параллельную реализацию для ускорения вычислений.

7. Практические рекомендации:

- Для задачи минимизации функции Растригина с $n = 2$ рекомендуется использовать: $N = 50$, $p_c = 0.7$, $p_m = 0.1$, $\sigma = 0.2$, элитизм 2 особи, турнирный отбор с $k = 3$.
- Для размерности $n = 10$ оптимальной показала себя конфигурация: $N = 100$, $p_c = 0.8$, $p_m = 0.1$, $\sigma = 0.2$.
- При увеличении размерности задачи следует пропорционально увеличивать размер популяции.
- Для мониторинга сходимости полезно отслеживать не только лучшее значение, но и разнообразие популяции.
- Критерий останова по стагнации (отсутствие улучшений в течение 20 поколений) хорошо работает на практике.

Таким образом, лабораторная работа позволила не только освоить принципы построения генетических алгоритмов, но и сформировать целостное представление о их месте в арсенале методов математического программирования, понимая как их сильные стороны в глобальном поиске, так и ограничения, связанные с вычислительной сложностью и тонкой настройкой параметров. Экспериментальные результаты наглядно демонстрируют как преимущества ГА для многоэкстремальных задач, так и необходимость тщательного подбора параметров для каждой конкретной задачи оптимизации.